

linear algebra - 1

$$A^T A \text{ is a symmetric matrix}$$

$$A^T A = \begin{pmatrix} 1 & 1 \\ 1 & -1 \\ 0 & 2 \end{pmatrix} \begin{pmatrix} 1 & 1 & 0 \\ 1 & -1 & 2 \end{pmatrix} = \begin{pmatrix} 2 & 0 & 2 \\ 0 & 2 & -2 \\ 2 & -2 & 4 \end{pmatrix}$$

$$x^2 - 6x + 12 = x(x-6) + 12$$

$$\det \begin{pmatrix} x-2 & 0 & -2 \\ 0 & x-2 & 2 \\ -2 & 2 & x-4 \end{pmatrix} = (x-2) \det \begin{pmatrix} x-2 & 2 \\ 2 & x-4 \end{pmatrix} - 2 \det \begin{pmatrix} 0 & -2 \\ x-2 & 2 \end{pmatrix} =$$

$$= (x-2) ((x-2)(x-4) - 4) - 4(x-2) = x^3 - 8x^2 + 12x = x(x-6)(x-2)$$

$$\lambda_1 = 6 \quad \lambda_2 = 2 \quad \lambda_3 = 0$$

$$x^2 - 6x + 12 = x(x-6) + 12$$

$$\ker(A^T A) = \ker \begin{pmatrix} 2 & 0 & 2 \\ 0 & 2 & -2 \\ 2 & -2 & 4 \end{pmatrix} \supset \mathbb{R}^3 : \underline{M}$$

$$\begin{pmatrix} 2 & 0 & 2 \\ 0 & 2 & -2 \\ 2 & -2 & 4 \end{pmatrix} \rightarrow \begin{pmatrix} 1 & 0 & 1 \\ 0 & 2 & -2 \\ 0 & -2 & 2 \end{pmatrix} \rightarrow \begin{pmatrix} 1 & 0 & 1 \\ 0 & 1 & -1 \\ 0 & 0 & 0 \end{pmatrix}$$

$$V_0 = \ker \begin{pmatrix} 2 & 0 & 2 \\ 0 & 2 & -2 \\ 2 & -2 & 4 \end{pmatrix} = \text{span} \left\{ \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix} \right\} \quad \text{or}$$

$$\ker \begin{pmatrix} 0 & 0 & 0 \\ 0 & 0 & -2 \\ 2 & -2 & 2 \end{pmatrix} \supset \mathbb{R}^3 : \underline{M_2}$$

$$\begin{pmatrix} 0 & 0 & 0 \\ 0 & 0 & -2 \\ 2 & -2 & 2 \end{pmatrix} \rightarrow \begin{pmatrix} 1 & -1 & 1 \\ 0 & 0 & 1 \\ 0 & 0 & 0 \end{pmatrix}$$

$$V_2 = \text{span} \left\{ \begin{pmatrix} 1 \\ 1 \\ 0 \end{pmatrix} \right\} \quad \text{or}$$

$$\text{Ker} \begin{pmatrix} -4 & 0 & 2 \\ 0 & -4 & -2 \\ 2 & -2 & -2 \end{pmatrix} \text{ dim: } \underline{1}$$

$$\begin{pmatrix} -4 & 0 & 2 \\ 0 & -4 & -2 \\ 2 & -2 & -2 \end{pmatrix} \rightarrow \begin{pmatrix} 1 & 0 & -0.5 \\ 0 & 1 & 0.5 \\ 0 & -1 & -0.5 \end{pmatrix} \rightarrow \begin{pmatrix} 1 & 0 & -0.5 \\ 0 & 1 & 0.5 \\ 0 & 0 & 0 \end{pmatrix}$$

$$V_C = \text{Ker} \begin{pmatrix} -4 & 0 & 2 \\ 0 & -4 & -2 \\ 2 & -2 & -2 \end{pmatrix} \approx \text{span} \left\{ \begin{pmatrix} 1 \\ 1 \\ 2 \end{pmatrix} \right\}$$

$$V = \begin{pmatrix} \frac{1}{\sqrt{6}} & \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{3}} \\ 0 & \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{3}} \\ \frac{1}{\sqrt{6}} & \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{3}} \end{pmatrix}$$

הערה:  $V$  היא מטריצה יחידה

$$\Sigma = \begin{pmatrix} \sqrt{6} & 0 & 0 \\ 0 & \sqrt{2} & 0 \\ 0 & 0 & 0 \end{pmatrix} \quad \text{כאן} \quad \Sigma^T \Sigma = \begin{pmatrix} 6 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 0 \end{pmatrix} \quad \text{כאן}$$

$AA^T$  היא e.v.d -  $\int$  נגזרת

$$AA^T = \begin{pmatrix} 1 & 1 & 0 \\ 1 & -1 & 2 \end{pmatrix} \begin{pmatrix} 1 & 1 \\ 1 & -1 \\ 0 & 2 \end{pmatrix} = \begin{pmatrix} 2 & 0 \\ 0 & 6 \end{pmatrix}$$

הערה:  $V$  היא מטריצה יחידה  $U = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$  היא מטריצה יחידה

$$A = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix} \begin{pmatrix} \sqrt{6} & 0 & 0 \\ 0 & \sqrt{2} & 0 \\ 0 & 0 & 0 \end{pmatrix} \begin{pmatrix} \frac{1}{\sqrt{6}} & \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{3}} \\ 0 & \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{3}} \\ \frac{1}{\sqrt{6}} & \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{3}} \end{pmatrix}$$

הערה:  $u \in \mathbb{R}^m$   $v \in \mathbb{R}^n$  (2)

$$A = v \otimes u = \begin{pmatrix} v_1 u_1 & v_1 u_2 & \dots & v_1 u_m \\ \vdots & \vdots & \ddots & \vdots \\ v_n u_1 & v_n u_2 & \dots & v_n u_m \end{pmatrix}$$

הערה:  $z_i, z_j$  הם וקטורים

הערה:  $z_i = v \cdot u_i$   $z_j = v \cdot u_j$

הערה:  $\text{rank}(A) = 1$   $A$  היא מטריצה רגולרית



$$\langle x, u_j \rangle = \left\langle \sum_{i=1}^n a_i u_i, u_j \right\rangle \stackrel{\text{linear}}{=} \sum_{i=1}^n a_i \langle u_i, u_j \rangle = a_j \langle u_j, u_j \rangle = a_j$$

כיוון ק	$V_i \otimes V_i$	היא סמטרית כי עבור כל $i$ ו- $j$ $i \neq j$ $V_i \otimes V_j$ נכנס
אלו $n$ זכר. $n$ זכר	נכנס סכום כל $V_i \otimes V_j$ סמטריות	הסכום (כיוון $n$ זכר) $V_i \otimes V_j$
ובעצם הסמטריות	כל $V_i \otimes V_j$ $V_i \otimes V_j$ $V_i \otimes V_j$	הם $V_i \otimes V_j$ $V_i \otimes V_j$ $V_i \otimes V_j$

1.  $\frac{1}{2} \frac{d}{dt} \left( \frac{1}{2} m v^2 \right) = \frac{1}{2} m v \frac{dv}{dt}$

על פי:  $x$  נערך הממוצע:  $\langle \sigma_i \sigma_{i+1} \rangle = 0.5$  כלומר נערך הממוצע  $\langle \sigma_i \sigma_{i+1} \rangle = 0.5$

$$= \sum_{j=1}^k v_j \sum_{i=k+1}^n v_j^T v_i = \sum_{j=1}^k v_j \cdot 0 = 0$$

$$v = \sum_{i=1}^k a_i v_i \quad \text{for } v \in V \quad \text{②}$$

$$P^2 = \sum_{i=1}^K V_i V_i^T \cdot \sum_{j=1}^K V_j V_j^T = \sum_{i=1}^K \sum_{j=1}^K V_i V_i^T V_j V_j^T \stackrel{(*)}{=} \sum_{i=1}^K V_i V_i^T V_i V_i^T = \sum_{i=1}^K V_i V_i^T = P$$

$$p(1-p)=0 \Leftrightarrow p-p^2=0 \Leftrightarrow p^2=p \quad \text{für } p=0 \quad \text{oder } p=1$$

5

$$h(\sigma) = g(f(\sigma)) = h'(\sigma) = g'(f(\sigma)) \cdot f'(\sigma) \quad g(x) = \frac{1}{2} \|x - y\|^2$$

$x_i$  מופיע בטרמין אחד בלבד

$$\frac{\partial g(x)}{\partial x_j} = \frac{\partial}{\partial x_j} \sum_{i \in [d]} (x_i - y)^2 = \sum_{i \in [d]} \frac{\partial (x_i - y)^2}{\partial x_j} = \sum_{i \in [d]} \frac{\partial (x_i^2 - 2x_i y + y^2)}{\partial x_j} = \frac{\partial x_j^2}{\partial x_j} - 2y = 2x_j - 2y$$

↑  
 $\frac{\partial x_i^2}{\partial x_j} = 2x_i \delta_{ij}$   
 $\frac{\partial (-2x_i y)}{\partial x_j} = -2y \delta_{ij}$

$$Dh(\sigma) = \frac{1}{2} Dg(f(\sigma) - y) \cdot Df(\sigma) = \frac{1}{2} (2f(\sigma) - y) \cdot Df(\sigma) = (f(\sigma) - y) \cdot Df(\sigma) \quad \text{1.5}$$

$$\nabla h(\sigma) = Df(\sigma)^T (f(\sigma) - y) \quad \text{1.5}$$

$$\zeta_j(x) = \frac{e^{x_j}}{\sum_{i=1}^n e^{x_i}}$$

6

נחשב את  $\zeta_j(x)$  כפונקציה של  $x$

$$\frac{\partial \zeta_j}{\partial x_i} = \frac{e^{x_j} \frac{\partial}{\partial x_i} \sum_{k=1}^n e^{x_k} - e^{x_j} \sum_{k=1}^n e^{x_k}}{\left( \sum_{k=1}^n e^{x_k} \right)^2} \quad \text{if } i=j \text{ then } \frac{\partial}{\partial x_i} \sum_{k=1}^n e^{x_k} = \sum_{k=1}^n e^{x_k}$$

$$\frac{\partial \zeta_j}{\partial x_i} = \frac{-e^{x_i} e^{x_j}}{\left( \sum_{k=1}^n e^{x_k} \right)^2} \quad \text{if } i \neq j \text{ then } \frac{\partial}{\partial x_i} \sum_{k=1}^n e^{x_k} = \sum_{k=1}^n e^{x_k}$$

המטריצה  $J(\sigma)$  היא מטריצה  $n \times d$  שבה  $J(\sigma)_{ij} = \frac{\partial \zeta_j}{\partial x_i}$



7. (10)  $\lim_{x \rightarrow 0} \frac{1}{x} \ln \left( \frac{1+x}{1-x} \right)$

$$Q = X^T X (N) \Rightarrow V^T X^T X V = 0 \Rightarrow (XV)^T XV = 0 \Rightarrow \|XV\|^2 = 0 \Rightarrow XV = 0 \quad ; \quad \sqrt{\frac{1}{N} X^T X} \quad \therefore$$

$$XV=0 \Rightarrow X^T(0)=0 \Rightarrow X^T(XN)=0 \Rightarrow X^T X N=0 \Rightarrow N \in \ker(X^T X)$$

$$\forall \in I_m(A^T) \quad \text{---} \quad \textcircled{2}$$

$$\langle V, u \rangle = 0 \quad \forall u \in K \cap N \quad \forall u \in K \cap N \quad \forall u \in K \cap N$$

$$| \phi \rangle, \quad A u = 0, \quad | \psi \rangle, \quad A^T u = v, \quad e, \quad \gamma, \quad w, \quad p, \quad \gamma$$

$$\langle v, u \rangle = \langle A^T w, u \rangle = \langle w, Au \rangle = \langle w, 0 \rangle = 0$$

$$I_m(A^\#) \subseteq K_{CV}(A) \quad 1.5$$

[illegible]

$$n = \dim_k \kappa(A) = \forall k(A)$$

p21  $n = \dim(\ker A^*) + \dim(\ker A) \leq n$   $\rho(A) = \rho(A^*)$

$$\dim(K(A)) = \dim(I_n(A)) - 1 \quad | 5$$

$$K_{\text{col}}(X^T)^{\perp} = I_m(X^T) = I_m(X) \quad \Rightarrow \text{find } \lambda' \text{ and } \lambda \quad (2)$$

$X|w=y$  ist eine normalverteilte Zuf. v.  $y \perp \text{ker}(X^T)$  d.h.  $y \in \text{Im } X$  ist

$X$  איז א פאקטאר וואס האט אן ענטיגער שטראם  
 $\{0\} \neq L(X) \subseteq \mathbb{R}$ . דאס מיינט אז  $e$  איז א פאקטאר וואס

$$x(u, v) = y \quad \text{für } u \in K(x) \text{ für } x \in C$$

3)  $x^T x$  e  $\sigma_c$

$$X^T X w = X^T y \Rightarrow (X^T X)^{-1} X^T X w = (X^T X)^{-1} X^T y \Rightarrow w = (X^T X)^{-1} X^T y$$

$$\langle u, x^T y \rangle = \langle x u, y \rangle = \langle 0, y \rangle = 0$$

$$w \in \ker(x) \iff w \in \ker(x^T x)$$

$X^T X \beta = X^T y$      $\text{rank}(X) = p$      $p > n$      $n < p$

$$X^T y \perp \ker(X^T X) \quad \square$$

$$u \in \ker(X^T X)$$

$$X = U \Sigma V^T$$

8

$$X^T X = (U \Sigma V^T)^T U \Sigma V^T = V \Sigma^T \Sigma V^T$$

$$X^T X \text{ פה } V \Sigma^T \Sigma V^T \text{ פה } V \Sigma^T \Sigma V^T$$

$$\Sigma^T \Sigma$$

$$X^T y = (X^T X)^{-1} X^T y$$

$$(X^T X)^{-1} = V (\Sigma^T \Sigma)^{-1} V^T$$

$$V \Sigma^T \Sigma V^T y = V (\Sigma^T \Sigma)^{-1} \Sigma^T \Sigma V^T y$$

$$X^T y = V \Sigma^T \Sigma V^T y \quad \text{②} \quad (X^T X)^{-1} X^T y = V (\Sigma^T \Sigma)^{-1} \Sigma^T \Sigma V^T y \quad \text{①} \quad \text{על פי}$$

$$\Sigma^T = (\Sigma^T \Sigma)^{-1} \Sigma^T \quad \text{פה } \Sigma^T \Sigma$$

$$\Sigma^T \Sigma \text{ פה } \Sigma^T \Sigma \text{ פה } \Sigma^T \Sigma$$

$$[\Sigma^T \Sigma]_{i,j} = \sum_{k=1}^m (\Sigma)_{i,k}^T \cdot (\Sigma)_{k,j} = (\Sigma)_{i,i}^T \cdot (\Sigma)_{i,j}$$

$$\text{כאשר } i=j \text{ } \sigma_i^2 \text{ } \text{פה } \sigma_i^2 \text{ } \text{פה } \sigma_i^2 \text{ } \text{פה } \sigma_i^2 \text{ } \text{פה } \sigma_i^2$$

$$(\Sigma^T \Sigma)^{-1} \Sigma^T y = \sum_{k=1}^m (\Sigma^T \Sigma)^{-1}_{i,k} \cdot \Sigma^T_{k,j} = (\Sigma^T \Sigma)^{-1}_{i,i} \cdot (\Sigma^T)_{i,j}$$

$$\frac{1}{\sigma_i^2} \text{ } \text{פה } \frac{1}{\sigma_i^2} \text{ } \text{פה } \frac{1}{\sigma_i^2}$$

$$\Sigma^T = (\Sigma^T \Sigma)^{-1} \Sigma^T \text{ } \text{פה } \Sigma^T \Sigma$$

$$X^T y = (X^T X)^{-1} X^T y \text{ } \text{פה } X^T y$$



# practical part

\* (3,1,3) \* כל המטרה היא להבין כיצד לבנות מודל טוב יותר

המטרה היא להבין את ה data

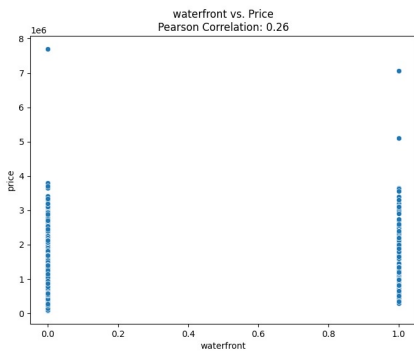
במסגרת המשימה הזו אנחנו צריכים לבנות מודל טוב יותר

במסגרת המשימה הזו אנחנו צריכים לבנות מודל טוב יותר


\* המטרה היא להבין את ה data

\* המטרה היא להבין את ה data

\* המטרה היא להבין את ה data



המטרה היא להבין את ה data



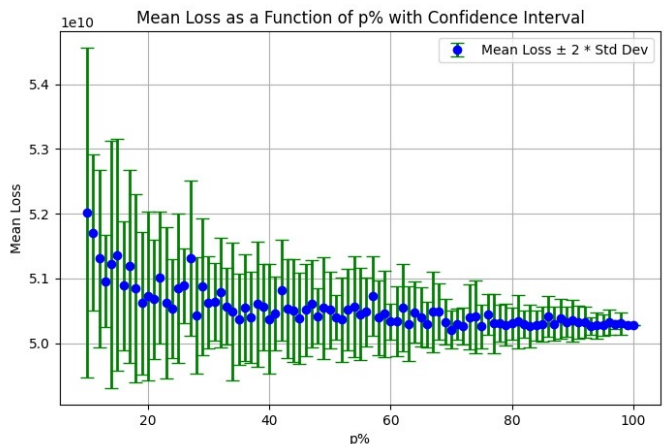
(3,1,4)

המטרה היא להבין את ה data

המטרה היא להבין את ה data

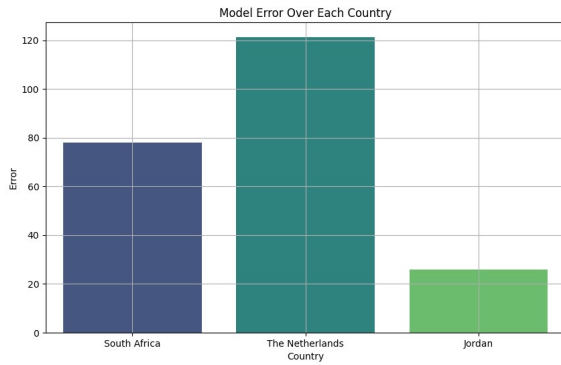
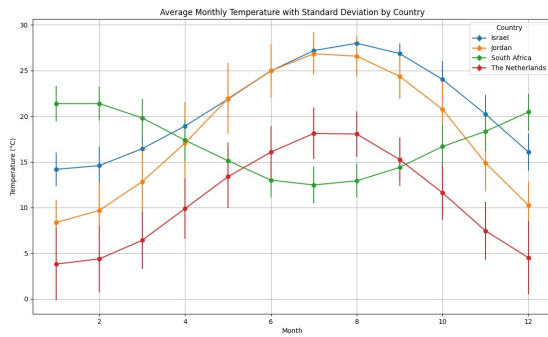
(3,1,6)

המטרה היא להבין את ה data









6) נכון לנתונים שהוצגו, המודל  
 עדיין אינו מדויק מספיק, ויש  
 להוסיף נתונים נוספים כדי  
 לשפר את הדיוק. לדוגמה, ניתן  
 להוסיף נתונים על טמפרטורת  
 המים, רמת הלחות או קרינת  
 השמש.